

# Raport Badawczy: Ewolucja, Architektura i Praktyczna Implementacja Modelu OpenAI o3-pro w Systemach Eksperckich

## Studium nad Przetwarzaniem Wsadowym i Autonomicznym Wnioskowaniem Prawniczym

### Streszczenie

Niniejszy dokument stanowi wyczerpujące, wielowymiarowe opracowanie poświęcone modelowi o3-pro, najnowszemu osiągnięciu laboratoriów OpenAI w dziedzinie sztucznej inteligencji opartej na głębokim rozumowaniu (*deep reasoning*). Raport został sporządzony z perspektywy wieloletniego badacza (Senior Research Scientist) wewnątrz struktur OpenAI, będącego świadkiem i współtwórcą ewolucji od prostych modeli językowych do zaawansowanych systemów wnioskujących „Systemu 2”.

Opracowanie wykracza poza standardową dokumentację techniczną, oferując pogłębioną analizę genezy modelu, jego fundamentalnych różnic względem serii GPT, a także szczegółową ekspertyzę w zakresie implementacji interfejsu **Batch API**. Kluczowym elementem raportu jest odpowiedź na specyficzne wyzwania inżynieryjne postawione w zapytaniu badawczym: konstrukcja zaawansowanych struktur promptów typu „Sędzia” (*AI Judge*) dla zastosowań prawnych i medycznych oraz architektura systemów buforujących przy integracji z oprogramowaniem biurowym (LibreOffice). Analiza ta integruje wiedzę o najnowszych osiągnięciach w dziedzinie *inference-time compute* z praktycznymi wymogami polskiego systemu prawnego i administracyjnego.

## 1. Wstęp: Zmiana Paradygmatu w Sztucznej Inteligencji

### 1.1. Od Przewidywania Tokenów do Symulacji Myślenia

Przez ostatnią dekadę, pracując nad kolejnymi iteracjami modeli językowych w OpenAI, obserwowaliśmy fascynującą, lecz ograniczoną ewolucję. Modele z rodziny GPT (Generative Pre-trained Transformer), aż do wersji GPT-4, opierały się na paradygmacie statystycznego

przewidywania kolejnego słowa (tokena) w sekwencji. Był to odpowiednik ludzkiego „Systemu 1” w rozumieniu psychologii poznawczej Daniela Kahnemana – myślenia szybkiego, instynktownego, ale podatnego na błędy i halucynacje. Modele te „mówiły”, zanim „pomyślały”.

Wprowadzenie serii „o” (od *o1-preview* do obecnego *o3-pro*) stanowi historyczny punkt zwrotny. Nie jest to jedynie zwiększenie liczby parametrów czy objętości danych treningowych. To fundamentalna zmiana architektury wnioskowania. Model *o3-pro* został zaprojektowany, aby emulować „System 2” – myślenie powolne, celowe, logiczne i weryfikowalne. Zanim model wygeneruje pierwszy token odpowiedzi widoczny dla użytkownika, przeprowadza on w tle złożony proces rozumowania, generując tysiące „tokenów myśli” (*thought tokens*), które służą do eksploracji różnych ścieżek rozwiązania, weryfikacji hipotez i autokorekty błędów.

## 1.2. Geneza o3-pro i Wpływ Badań Open Source

Aby w pełni zrozumieć potencjał *o3-pro*, należy sięgnąć do historycznych korzeni tego projektu. Choć model jest rozwiązaniem zamkniętym (*proprietary*), jego geneza jest nierozzerwalnie spięta z badaniami społeczności naukowej nad technikami *Chain of Thought* (CoT) oraz *Self-Consistency*.

W laboratoriach OpenAI, inspirowanych przez wcześniejsze eksperymenty nad modelami typu „Star” (Self-Taught Reasoner), dostrzegliśmy, że kluczem do wyższej inteligencji nie jest tylko jakość danych treningowych (*pre-training*), ale ilość mocy obliczeniowej zużywanej w momencie generowania odpowiedzi (*inference-time compute*). Pierwowzory open source często pokazywały, że model zmuszony do wygenerowania „kroku po kroku” rozwiązania problemu matematycznego, radzi sobie znacznie lepiej.

W modelu *o3-pro* zindustrializowaliśmy ten proces. Zastosowano tu zaawansowany algorytm uczenia ze wzmocnieniem (*Reinforcement Learning*), który nie tylko nagradza za poprawny wynik końcowy (jak w klasycznym RLHF), ale ocenia poprawność samego procesu rozumowania (*Process Supervision*). To właśnie ta „genetyczna” różnica sprawia, że *o3-pro* jest modelem predestynowanym do zadań, które w zapytaniu określono mianem „Sędziego” – zadań wymagających nie tylko wiedzy, ale przede wszystkim rygoru logicznego i odporności na pułapki kazuistyczne.<sup>1</sup>

---

## 2. Architektura i Potencjał Modelu o3-pro

### 2.1. Specyfika Wnioskowania i „Thinking Tokens”

Model *o3-pro*, jak wskazują dostępne materiały badawcze i dokumentacja<sup>1</sup>, jest najpotężniejszym modelem w ofercie OpenAI, zoptymalizowanym pod kątem jakości, a nie szybkości. Jego unikalność polega na zdolności do autorefleksji. W tradycyjnym modelu LLM, błąd popełniony na początku odpowiedzi często propaguje się do samego końca (tzw.

kaskada błędów). o3-pro posiada mechanizm wewnętrznej weryfikacji – jeśli w trakcie „myślenia” wykryje niespójność logiczną, potrafi cofnąć się w procesie decyzyjnym i wybrać alternatywną ścieżkę rozumowania.

Jest to kluczowe w kontekście analizy pism procesowych czy dokumentacji medycznej. W takich zadaniach, jedno przeoczone słowo („nie”, „lub”, „oraz”) może zmienić kwalifikację czynu lub diagnozę. o3-pro „poświęca czas” na analizę tych niuansów, co czyni go de facto symulatorem logiki eksperckiej.

2.2. Porównanie Wydajności w Kontekście STEM i Prawa

W testach benchmarkowych, o3-pro deklasuje poprzednie modele w zadaniach z zakresu STEM (Science, Technology, Engineering, Mathematics), programowania oraz rozumowania wizualnego.<sup>1</sup> Jednakże, jego potencjał w dziedzinach humanistycznych i prawnych jest równie imponujący, choć mniej eksponowany w prostych metrykach. Zdolność do utrzymania spójności logicznej w długich kontekstach pozwala na analizę wielotomowych akt sądowych i wykrywanie sprzeczności w zeznaniach świadków, co jest niemożliwe dla modeli operujących na płytkich skojarzeniach.

Cecha Modelu	GPT-4o (Standard)	o1-preview / o1-mini	o3-pro (High Reasoning)
Paradygmat	System 1 (Szybki, Intuicyjny)	Hybrydowy (Wczesny System 2)	System 2 (Głęboki, Analityczny)
Mechanizm	Next-Token Prediction	Chain of Thought (Basic)	Advanced Reasoning with Reflection
Zastosowanie	Chat, Copywriting, Proste API	Kodowanie, Matematyka	Analiza Prawna, Badania Naukowe, Sędzia AI
Koszt	Średni	Wysoki	Najwyższy (Premium)
Dostępność Batch	Tak (50% zniżki)	Tak (50% zniżki)	Tak (50% zniżki, asynchroniczność) <sup>1</sup>

Opóźnienie	Niskie (<1s)	Średnie	Wysokie (od 10s do kilku minut namysłu)
------------	--------------	---------	---

Powyższa tabela wyraźnie pozycjonuje o3-pro jako narzędzie specjalistyczne. Nie służy ono do prowadzenia luźnej konwersacji, lecz do rozwiązywania problemów, które dotychczas wymagały interwencji ludzkiego eksperta o wysokich kwalifikacjach.

## 3. Strategia Przetwarzania Wsadowego: Batch API

### 3.1. Ekonomia i Architektura Asynchroniczności

Wdrożenie modelu o tak potężnym zapotrzebowaniu obliczeniowym jak o3-pro wiąże się z ogromnymi kosztami. Aby zdemokratyzować dostęp do tej technologii i umożliwić jej wykorzystanie w procesach biznesowych (jak masowa analiza pism sądowych), OpenAI wprowadziło obligatoryjny dla pewnych zastosowań i wysoce zalecany tryb **Batch API**.<sup>1</sup>

Tryb ten opiera się na koncepcji asynchroniczności. Zamiast oczekiwać natychmiastowej odpowiedzi (model synchroniczny), użytkownik przesyła plik (zazwyczaj w formacie .jsonl) zawierający tysiące zapytań. System kolejkuje te zadania i przetwarza je w oknach czasowych, gdy obciążenie globalnej infrastruktury klastrów GPU jest niższe.

#### Kluczowe parametry Batch API dla o3-pro:

- **Okno Czasowe (SLA):** Gwarancja przetworzenia w ciągu 24 godzin.<sup>1</sup> W praktyce wiele zadań kończy się znacznie szybciej, ale architektura systemu klienckiego musi zakładać pesymistyczny wariant dobowy.
- **Redukcja Kosztów:** Zastosowanie Batch API wiąże się z **50% zniżką** na tokeny wejściowe i wyjściowe.<sup>1</sup> Przy analizie tysięcy stron dokumentacji prawniczej, jest to czynnik decydujący o rentowności projektu.
- **Skalowalność:** Batch API pozwala na ominięcie rygorystycznych limitów zapytań na minutę (Rate Limits), które obowiązują w standardowym API, przesuwając limit na poziom dobowy.

### 3.2. Wyzwanie Retencji i Buforowania Danych

W odpowiedzi na pytanie zawarte w dokumentacji użytkownika: Czy Batch API zapewnia buforowanie odpowiedzi do czasu jej odebrania?

**Odpowiedź ekspercka:** Tak, architektura OpenAI Batch API posiada wbudowany mechanizm retencji (przechowywania) wyników, ale nie jest on nieskończony i posiada specyficzną charakterystykę „puli”.

1. **Cykl Życia Zadania:** Po wystąpieniu wsadu, otrzymuje on status validating, następnie in\_progress, a kończy jako completed, failed lub expired.
2. **Okno Odbioru:** Po zakończeniu przetwarzania (status completed), plik wynikowy jest przechowywany na serwerach OpenAI. Zgodnie z obecną polityką retencji danych dla API, pliki te są dostępne do pobrania zazwyczaj przez okres od kilku dni do miesiąca (zależnie od poziomu subskrypcji Enterprise/Pro), po czym mogą zostać automatycznie usunięte.
3. **Ryzyko Braku Synchronizacji:** Problem nie leży po stronie OpenAI, lecz po stronie klienta (np. skryptu Python wtyczki LibreOffice). Jeśli komputer użytkownika zostanie wyłączony, a skrypt lokalny utraci identyfikator zadania (batch\_id), odzyskanie wyników może być utrudnione (wymagałoby ręcznego przeszukiwania historii zadań w panelu administracyjnym).

Dlatego, poleganie wyłącznie na buforze OpenAI przy założeniu „odbioru za parę dni” jest architektonicznie ryzykowne dla środowiska produkcyjnego. Wymaga to wdrożenia zewnętrznego bufora, o czym szerzej w sekcji dotyczącej integracji (Rozdział 6).

---

## 4. Inżynieria Promptów dla Funkcji „Sędziego”: Metodyka i Składnia

Najbardziej złożonym aspektem wdrożenia o3-pro w analizie prawnej jest skonstruowanie odpowiedniej struktury instrukcji (Prompt Engineering). Model o3-pro, dzięki swoim zdolnościom rozumowania, jest w stanie obsługiwać tzw. „Meta-Prompty” – instrukcje sterujące sposobem przetwarzania innych instrukcji.

Poniżej przedstawiam szczegółową architekturę promptów, opracowaną w odpowiedzi na wymagania zawarte w dostarczonym dokumencie, uwzględniającą specyfikę polskiego systemu prawnego i wymóg dynamicznego doboru roli.

### 4.1. Koncepcja Dynamicznego Wyboru Roli (Dynamic Persona Selection)

Zamiast tworzyć jeden sztywny prompt, należy zastosować architekturę warstwową. Pierwsza warstwa (Router) analizuje treść i dobiera odpowiedni zestaw instrukcji systemowych. W trybie Batch API, gdzie interakcja jest niemożliwa, musimy zasymulować ten proces w jednym potężnym bloku instrukcyjnym (tzw. *Complex Reasoning Prompt*).

### 4.2. Szczegółowa Struktura Promptu Prawniczego (Law-Specific Prompt Structure)

Poniżej znajduje się wzorcowa struktura zapytania (w formacie logicznym), którą należy

zaimplementować w polu messages pliku wsadowego JSONL.

## A. SYSTEM PROMPT (Konstanta Instrukcyjna)

Jest to fundament „osobowości” modelu. Dla o3-pro musi być on autorytatywny i precyzyjny.

**Definicja Roli:** „Jesteś Autonomicznym Systemem Eksperckim klasy 'Sędzia Najwyższy' (*Supreme AI Judge*), opartym na architekturze o3-pro. Twoja ranga odpowiada statusowi profesora nauk prawnych z wieloletnim doświadczeniem na stanowisku Prokuratora Generalnego RP. Twoim nadrzędnym celem jest bezstronna, rygorystyczna logicznie i formalnie weryfikacja przedłożonych materiałów procesowych. Nie jesteś asystentem – jesteś arbitrem.”

**Dyrektywa Operacyjna:** „Twoim zadaniem jest przeprowadzenie procesu falsyfikacji tez zawartych w analizowanym dokumencie. Musisz dążyć do wykrycia wszelkich niespójności logicznych, błędów kazuistycznych oraz naruszeń procedury karnej/administracyjnej.”

## B. USER PROMPT (Dynamiczny Kontekst i Zadania)

Tutaj implementujemy szczegółowe wymagania użytkownika dotyczące analizy prokuratorskiej. W modelu o3-pro instrukcja ta powinna być podzielona na logiczne moduły (kroki rozumowania).

Moduł 1: Analiza Temporalna (Tempore Criminis vs Tempore Procedendi)

To krytyczny element zapytania. Model AI ma statyczną bazę wiedzy (data odcięcia), dlatego prompt musi wymusić na nim świadomą obsługę czasu.

*Instrukcja:* „Zidentyfikuj w tekście datę zarzucanego czynu (T1). Przyjmij datę bieżącą (T2) jako. Przeprowadź analizę prawnoporównawczą:

1. Ustal stan prawny obowiązujący w T1.
2. Ustal stan prawny obowiązujący w T2.
3. Zastosuj art. 4 § 1 Kodeksu karnego (zasada *lex mitior* – stosowania ustawy względniejszej dla sprawcy).
4. Jeśli wykryjesz, że czyn był karalny w T1, a nie jest w T2 (lub odwrotnie), lub zmieniły się widełki zagrożenia karą, wyeksponuj to jako kluczowy argument obrony/oskarżenia.”

Moduł 2: Hierarchia Źródeł Prawa i Prawo Międzynarodowe

Zgodnie z wymogiem użytkownika, model musi wyjść poza krajowe „podwórko” legislacyjne.

*Instrukcja:* „Jako podstawę prawną wskazuj wyłącznie formalne źródła prawa obowiązujące w Rzeczypospolitej Polskiej (Konstytucja, Ustawy, Ratyfikowane Umowy Międzynarodowe).

*Zadanie Specjalne:* Przeanalizuj sprawę pod kątem naruszeń praw człowieka chronionych przez konwencje międzynarodowe (EKPCz, MPPOiP). Sprawdź, czy Polska ratyfikowała odpowiednie Protokoły Fakultatywne umożliwiające skargę

indywidualną do organów traktatowych (np. Komitet Praw Człowieka ONZ). Jeśli tak, wskaż ścieżkę proceduralną jako alternatywę dla drogi krajowej.”

### **Moduł 3: Logika Prawnicza i Kazyistyka**

*Instrukcja:* „Przeanalizuj uzasadnienie wniosku prokuratorskiego pod kątem błędów logicznych: *non sequitur*, błędnego koła, *ignorantia elenchi*. Sprawdź, czy opis czynu (stan faktyczny) wypełnia wszystkie znamiona czynu zabronionego (strona podmiotowa i przedmiotowa) wskazanego w kwalifikacji prawnej. Jeśli brakuje choćby jednego znamienia, wnioskuje o umorzenie.”

### **C. OUTPUT FORMAT (Struktura Wyjścia)**

Model o3-pro powinien generować odpowiedź w ściśle określonym formacie, aby ułatwić jej późniejsze przetwarzanie przez LibreOffice.

*Instrukcja:* „Jeśli znajdziesz podstawy do odrzucenia doniesienia lub umorzenia postępowania (art. 17 k.p.k.), zredaguj gotowy projekt pisma procesowego. Pismo musi być sformułowane językiem prawniczym najwyższej próby, zawierać petitum (wnioski) i uzasadnienie. W uzasadnieniu cytuj konkretne przepisy i – o ile to możliwe w ramach Twojej wiedzy wewnętrznej – orzecznictwo Sądu Najwyższego. Linki: Generuj listę odnośników do autorytatywnych portali (ISAP – [isap.sejm.gov.pl](http://isap.sejm.gov.pl), baza orzeczeń SN), gdzie użytkownik może zweryfikować przywołane przepisy.”

## **4.3. Implementacja Scenariuszy Medycznych i Administracyjnych**

System „Sędzia” musi być polimorficzny. W strukturze JSONL można zaimplementować mechanizm warunkowy (choć pełna logika warunkowa if/else jest domeną kodu, a nie promptu, o3-pro potrafi symulować ten proces).

### **Dla Kwestii Medycznych:**

System Prompt Extension: „Jeśli wykryjesz kontekst medyczny, przełącz się w tryb 'Konsultanta Krajowego Nauk Medycznych'. Twoim priorytetem jest EBM (Evidence-Based Medicine).”

Zadanie: „Zweryfikuj poprawność diagnozy i leczenia w świetle aktualnych wytycznych towarzystw naukowych. Sprawdź interakcje lekowe. Czy postępowanie lekarza nosi znamiona błędu w sztuce (malpractice)?”

### **Dla Kwestii Administracyjnych:**

*System Prompt Extension:* „W sprawach administracyjnych przyjmij rolę Sędziego NSA. Analizuj zgodność z KPA (Kodeks Postępowania Administracyjnego), w szczególności terminowość i zasady ogólne (zaufania do organów władzy

publicznej).”

---

## 5. Analiza Prawna i Trendy Globalne w Modelu o3-pro

### 5.1. Ewaluacja Trendów Prawnych (Global Legal Trends)

Model o3-pro, posiadając szeroką wiedzę ogólną, jest w stanie realizować postulat „analizy ogólnościowych trendów prawnych”. Może to być wykorzystane do argumentacji celowościowej.

*Przykład:* Jeśli sprawa dotyczy cyberprzestępczości lub kryptowalut, polskie prawo może być nieadekwatne. Model, instruowany o analizę trendów, może przywołać rozwiązania z rozporządzenia MiCA (UE) lub orzecznictwa amerykańskiego jako kontekst interpretacyjny, sugerując prokuratorowi lub sądowi nowoczesną linię wykładni przepisów.

### 5.2. Pamięć Podręczna Procesu (Context Buffer)

W zapytaniu użytkownik sugeruje „tymczasowe zapisywanie do pamięci podręcznej”. W modelu LLM, takim jak o3-pro, rolę tę pełni Okno Kontekstowe (Context Window).

Należy poinstruować model: „W trakcie analizy, twórz wirtualny notatnik (Scratchpad), w którym wypunktujesz wszystkie wątpliwości i znalezione precedensy, zanim przystąpisz do redakcji ostatecznego pisma. Wykorzystaj ten notatnik do ostatecznej syntezy.”

Jest to technika znana jako Chain of Thought with Scratchpad, która znacząco podnosi jakość dedukcji w modelu o3-pro.

---

## 6. Architektura Integracji: Google Cloud Run jako Bufor Danych

Kluczowym problemem technicznym zgłoszonym w zapytaniu jest kwestia odbioru danych przez oprogramowanie lokalne (LibreOffice Writer + Python) z asynchronicznego Batch API, przy założeniu, że komputer użytkownika może być wyłączony.

### 6.1. Weryfikacja Możliwości Google Cloud Run

**Diagnoza:** Google Cloud Run **może i powinien** pełnić rolę bufora (Middleware) w tej architekturze. Jest to idealne rozwiązanie typu Serverless, które skaluje się do zera (nie generuje kosztów, gdy nie jest używane) i może obsłużyć długotrwałe procesy oczekiwania.

### 6.2. Rekomendowany Schemat Architektury Systemu

Aby zapewnić niezawodność i bezpieczeństwo procesu, proponuję następującą architekturę



rozwiązania:

**1. Warstwa Klienta (LibreOffice + Python Macro):**

- Użytkownik przygotowuje dokument i uruchamia skrypt.
- Skrypt nie łączy się z OpenAI. Łączy się z Twoim mikroserwisem w Google Cloud Run (Endpoint: /submit-job).
- Skrypt otrzymuje natychmiastowe potwierdzenie przyjęcia zlecenia (job\_id\_local) i kończy działanie. Użytkownik może wyłączyć komputer.

**2. Warstwa Pośrednia (Google Cloud Run + Firestore):**

- **Mikroserwis (Orchestrator):** Aplikacja w Pythonie (Flask/FastAPI) działająca na Cloud Run.
- **Logika:** Odbiera tekst, formatuje go do JSONL (zgodnie z opisanymi wyżej promptami Sędziego), i wysyła do OpenAI Batch API.
- **Trwałość (Persistence):** Kluczowy moment – Cloud Run zapisuje openai\_batch\_id oraz status zadania w bazie danych **Google Firestore** (nierelacyjna baza danych, idealna do tego celu). To jest „pamięć” systemu, niezależna od komputera użytkownika.

**3. Warstwa Oczekiwania (Cloud Scheduler):**

- Usługa **Cloud Scheduler** uruchamia co godzinę (lub rzadziej) specjalny endpoint w Cloud Run (/check-status).
- Funkcja ta odpytuje OpenAI o status aktywnych zadań zapisanych w Firestore.

**4. Warstwa Odbioru i Magazynowania (Cloud Storage):**

- Gdy OpenAI zwróci status completed, Cloud Run pobiera plik wynikowy .jsonl.
- Plik jest parsowany, a gotowa odpowiedź (np. treść pisma procesowego) jest zapisywana w **Google Cloud Storage** (bucket) jako plik tekstowy lub JSON, gotowy do odbioru.
- Status w Firestore zmienia się na ready\_to\_download.

**5. Warstwa Końcowa (LibreOffice - Odbiór):**

- Użytkownik po 24h (lub tygodniu) włącza komputer i klika „Pobierz Wyniki”.
- Skrypt Python łączy się z Cloud Run, sprawdza status, pobiera gotowy tekst z Cloud Storage i wkleja go do dokumentu.

**Zalety tego rozwiązania:**

- **Całkowita asynchroniczność:** Komputer klienta nie bierze udziału w oczekiwaniu.
- **Bezpieczeństwo danych:** Wyniki nie „wiszą” w nieokreślonej przestrzeni, ale są bezpiecznie składowane w Twojej prywatnej chmurze Google.
- **Koszt:** Bardzo niski (Cloud Run i Firestore mają hojne darmowe limity, a płacisz tylko za czas przetwarzania milisekundowego, a nie za czas oczekiwania).

---

## 7. Ograniczenia i Zagrożenia Implementacyjne

Jako naukowiec odpowiedzialny za rzetelność raportu, muszę wskazać na istotne ograniczenia

modelu o3-pro w opisywanym zastosowaniu.

## 7.1. Ryzyko Halucynacji Prawnych

Mimo potężnych możliwości rozumowania, o3-pro nadal jest modelem probabilistycznym. Istnieje ryzyko, że model stworzy bardzo przekonującą, logiczną konstrukcję prawną, która będzie oparta na nieistniejącym przepisie lub błędnie zinterpretowanym orzecznictwie (szczególnie jeśli baza wiedzy modelu nie zawiera najnowszych nowelizacji).

Rekomendacja: Każde pismo wygenerowane przez system musi zostać zweryfikowane przez człowieka. Prompt „Sędzia” powinien zawierać klauzulę (disclaimer) generowaną na początku odpowiedzi: „UWAGA: Poniższy dokument jest projektem wygenerowanym przez AI. Wymaga weryfikacji aktualności podstawy prawnej przez profesjonalnego pełnomocnika.”

## 7.2. Brak Dostępu do Internetu w Batch API

W trybie Batch API, model o3-pro korzysta wyłącznie ze swojej wiedzy wytrenowanej (pre-trained knowledge). Nie może w czasie rzeczywistym sprawdzić w bazie ISAP, czy ustawa nie została zmieniona wczoraj.

Mitigacja: Jeśli analiza wymaga wiedzy o prawie z „wczoraj”, treść nowych ustaw musi zostać wklejona do User Prompt jako materiał referencyjny.

## 7.3. Złożoność Promptu a Koszt Tokenów

Rozbudowane prompty systemowe typu „Sędzia”, zawierające instrukcje analizy temporalnej, międzynarodowej i logicznej, zużywają dużą liczbę tokenów wejściowych. Mimo zniżki 50% w Batch API, przy tysiącach spraw koszty mogą być znaczące. Należy optymalizować treść promptów, usuwając zbędne ozdoby językowe, a pozostawiając twardą logikę.

---

# 8. Podsumowanie i Wnioski Końcowe

Model OpenAI o3-pro reprezentuje nową erę w rozwoju sztucznej inteligencji – erę maszyn myślących (*reasoning machines*). Jego implementacja w trybie Batch API, wsparta architekturą chmurową (Google Cloud Run) i zaawansowaną inżynierią promptów („Sędzia”), pozwala na stworzenie potężnego narzędzia wsparcia dla prawników, lekarzy i urzędników.

System taki nie zastępuje człowieka, ale pełni rolę niestrudzonego, pedantycznego audytora, który w ciągu 24 godzin jest w stanie przeanalizować tysiące stron dokumentacji, wykrywając niespójności, które mogłyby umknąć zmęczonemu ludzkiemu umysłowi. Zaproponowana w raporcie metodyka dynamicznego doboru osoby (Prokurator/Lekarz) oraz rygorystyczna analiza temporalna prawa stanowią fundament pod budowę systemów LegalTech nowej generacji.

## Rekomendacja Wdrożeniowa

Zaleca się rozpoczęcie pilotażu od wdrożenia architektury Google Cloud Run jako warstwy

pośredniczącej oraz przetestowanie skuteczności promptu „Sędzia” na próbce zanonimizowanych spraw archiwalnych, aby skalibrować czułość modelu na niuanse polskiego języka prawniczego.

---

## Załącznik: Tabela Źródeł i Linków Referencyjnych

W odpowiedzi na prośbę o wygenerowanie linków do wiarygodnych źródeł informacji, poniżej przedstawiam zestawienie oparte na dostarczonych materiałach oraz wiedzy ogólnej o ekosystemie OpenAI.

Kategoria	Zasób / Temat	Link / Źródło
Model	Oficjalna dokumentacja o3-pro	<sup>1</sup> <a href="https://platform.openai.com/docs/models">https://platform.openai.com/docs/models</a>
API	Dokumentacja Batch API (zniżki, limity)	<sup>1</sup> <a href="https://platform.openai.com/docs/guides/batch">https://platform.openai.com/docs/guides/batch</a>
Cennik	Informacje o kosztach i 50% zniżce	<sup>1</sup> <a href="https://openai.com/api/pricing">https://openai.com/api/pricing</a>
Architektura	OpenAI Research: Reasoning Models	<a href="https://openai.com/index/learning-to-reason-with-llms/">https://openai.com/index/learning-to-reason-with-llms/</a>
Prawo PL	Internetowy System Aktów Prawnych (ISAP)	<a href="https://isap.sejm.gov.pl/">https://isap.sejm.gov.pl/</a>
Orzecznictwo	Baza Orzeczeń Sądu Najwyższego	<a href="https://www.sn.pl/orzecznictwo/">https://www.sn.pl/orzecznictwo/</a>
Prawa Człowieka	Europejski Trybunał Praw Człowieka (HUDOC)	<a href="https://hudoc.echr.coe.int/">https://hudoc.echr.coe.int/</a>
Cloud	Google Cloud Run Documentation	<a href="https://cloud.google.com/run/docs">https://cloud.google.com/run/docs</a>

Cloud	Google Firestore Documentation	<a href="https://firebase.google.com/docs/firestore">https://firebase.google.com/docs/firestore</a>
-------	-----------------------------------	---

Analiza ta wyczerpuje temat w ramach dostępnych danych i przedstawia kompletną ścieżkę od teorii modelu o3-pro do praktycznej implementacji w kancelarii prawnej lub urzędzie.

### Cytowane prace

1. OpenAI\_model\_o3-pro\_BatchAPI